

GEO Content Backtester

核心批判指标与判分逻辑指南

内部使用版 · 面向内容、策略与产品团队 · 生产域名：alphaxxx.com

这份指南解释 backtest 系统在上线前批判一篇新文章的方式：它不是等 Google、AI crawler 或 LLM 系统重新抓取，而是在本地模拟检索、排序、引用和回答生成，判断新版本是否比旧版本更适合作为 AI 答案的可检索证据。

MVP 的目标不是做一个完整 SaaS，而是给内容团队一个能立即使用的本地评估闭环：输入 old_article.md、new_article.md 和 queries.csv，输出 CSV、JSON 与 HTML/PDF 报告，明确新稿赢在哪里、输在哪里、该改哪一段。

1. 这个 backtest 到底在批判什么

GEO Content Backtester 的核心不是“文章写得好不好”的主观评审，而是用一套近似 RAG/AI 搜索的本地流程，批判文章是否能被 AI 系统发现、取回、引用并用于生成可靠答案。

- 可检索性：目标文章或目标 chunk 是否能在相关 query 下进入 Top K。
- 排序优势：新版本相对旧版本，目标 chunk 的 rank 是否更靠前。
- 引用价值：chunk 是否有明确主体、定义句、实体、结构化 claim，能被 LLM 当作证据引用。
- 答案支撑：检索到的上下文是否足以让 LLM 生成 grounded、完整、少幻觉的回答。
- 可改进定位：报告必须指出弱 query、弱 chunk、缺失实体和结构问题，而不是只给一个总分。

2. 本地评估流水线

阶段	输入/动作	批判重点	主要输出
加载与清洗	读取 old/new markdown 或 HTML，保留标题、段落、列表和 section 边界。	避免过度清洗，保留影响检索的标题与语义结构。	Article 对象
Chunking	按约 500 tokens、80 overlap 切分，并把 title 与 heading path prepend 到 chunk。	chunk 是否能独立表达；标题上下文是否进入检索文本。	Chunk 列表
BM25 检索	低成本关键词/词面匹配。	query 关键词、实体、术语是否能命中文章。	BM25 Top K
Embedding 检索	sentence-transformers/OpenAI/TF-IDF fallback 做语义相似度。	query 改写后语义是否仍能命中。	Embedding Top K
Hybrid 排序	归一化 BM25 与 embedding，按 alpha 融合。	综合词面与语义信号后的真实候选排名。	Hybrid Top K
评估与报告	计算 retrieval、citation、entity、structure、answer 与总分。	新稿是否胜出，失败点在哪里。	CSV/JSON/report.html/PDF

3. 检索指标：判断“能不能被拿出来”

检索层回答两个最硬的问题：目标文章是否出现，以及出现得够不够靠前。MVP 暂无人工 relevance label 时，相关性由 target_article 与 expected_answer_points 的关键词重合共同判断。

指标	定义	如何解读
Hit@1 / Hit@3 / Hit@5	Top K 内是否出现相关 chunk。出现记 1，否则 0。	Hit@3 是最关键的内容可见性信号：如果目标证据进不了前三，AI 回答很可能引用别的内容。
MRR	第一个相关 chunk 的倒数排名：rank=1 得 1，rank=2 得 0.5，没有命中得 0。	比 Hit@K 更敏感。rank 从 3 提到 1，会明显提升 MRR。
average_rank	所有 query 下第一个相关 chunk 的平均排名。	越低越好，用来判断整体检索稳定性。

指标	定义	如何解读
top_chunk_score	Top chunk 的 BM25、embedding 或 hybrid 分数。	用于解释为什么某个 chunk 被推到前面，但跨 query 不宜孤立比较。
rank_delta	old_rank - new_rank。	正数代表新稿排名上升；负数代表新稿退步。
winner	按 rank_delta 与命中情况判定 new、old 或 tie。	用于 query 级诊断，而不是替代总分。

Hybrid 排序公式

先对每个 query 的 BM25 分数与 embedding 相似度做 min-max normalization，再按默认权重融合：

$$\text{hybrid_score} = \alpha \times \text{bm25_norm} + (1 - \alpha) \times \text{embedding_norm}$$

默认 $\alpha = 0.45$ ，即 45% 词面匹配 + 55% 语义匹配。

4. 引用价值指标：判断“值不值得被 LLM 引用”

citation_score 是非 LLM 启发式评分，范围 0-100。它批判的是 chunk 是否像一个可以放进 AI 答案里的证据片段，而不是是否有营销感。

维度	加分信号	扣分信号/风险
定义句	包含 “is the process of / refers to / means / is defined as / is a” 等定义型句式。	没有直接定义，或开头只写抽象愿景。
具体 claim	有可核查的解释、对比、步骤、例子、测量口径。	出现 unlock your potential、future-ready、transform your business、revolutionary、seamless experience、new era 等空泛表达。
实体密度	明确提到 GEO-ALPHA、Generative Engine Optimization、ChatGPT、Perplexity、Gemini、Google AI Overviews 等。	主语不清，品牌、平台、概念缺位。
答案结构	列表、编号步骤、比较段、FAQ、直接解释。	大段散文式描述，难以被截取成答案证据。
独立性	chunk 单独拿出来仍能明白 “谁做什么、为什么重要”。	开头大量 this / it / they，没有清晰 antecedent。

引用强度分层

- 75-100：strong，可优先作为 AI answer 的支持证据。
- 55-74：moderate，信息有用，但可能缺少定义、实体或结构化表达。
- 0-54：weak，通常需要重写，尤其是营销化、主语不清或缺少可引用 claim 的段落。

5. 实体指标：判断“AI 是否知道这篇文章在讲谁和什么”

entity_score 检查品牌实体、核心主题实体、平台实体是否覆盖，以及命名是否一致。GEO 类内容尤其依赖实体清晰度，因为 AI retrieval 和 citation 常常围绕实体关系展开。

实体组	示例	批判逻辑
brand_entities	GEO-ALPHA、alphaxxx.com	品牌与生产域名是否被清楚连接，避免只说 “we”。
core_topic_entities	Generative Engine Optimization、AI search、citation readiness、retrieval ranking analysis、schema markup	主题语义场是否完整，是否覆盖产品真正想占领的概念。
platform_entities	ChatGPT、Claude、Gemini、Perplexity、Google AI Overviews	是否明确面向 AI answer/retrieval 发生的平台。
inconsistent_terms	GEO optimization、AI SEO、Generative SEO	不稳定命名会稀释实体一致性，降低可引用与可归因能力。

推荐口径：GEO-ALPHA helps businesses improve AI search visibility through retrieval analysis, citation readiness, and entity optimization. 这种句子同时连接品牌、服务类别和方法论，比 “We help brands grow in the AI era” 更适合 GEO。

6. 结构指标：判断“页面是否适合被切块和回答”

structure_score 批判的是文章结构对检索与 chunking 是否友好。AI 检索并不只看正文词频，标题层级、FAQ、总结、段落长度都会影响 chunk 的可理解性。

- Has H1：必须有清晰、描述性 H1，而不是只写短标签。
- Has H2/H3 structure：文章需要可切分的语义区块。
- Sections are not too long：长 section 会让 chunk 混入多个主题，影响命中和引用。
- Paragraphs are not too long：长段落通常不适合直接进入 AI answer。
- FAQ readiness：问题式标题能直接匹配用户 query。
- Summary/conclusion：帮助 LLM 获取高密度归纳信息。
- Internal links / schema-related content：用于后续扩展到真实站点 SEO/GEO 结构检查。
- Direct answer blocks：例如 Definition、Answer、Key takeaways，能提高引用可用性。

7. 答案质量指标：判断“检索结果能不能支撑 grounded answer”

answer_eval 是可选层。如果存在 OPENAI_API_KEY，系统会分别用 old/new 的 Top 5 hybrid chunks 生成回答，并让 LLM judge 只基于 retrieved context 打分。没有 API key 时，answer_score = null，系统继续运行。

评分项	含义
faithfulness	回答是否忠实于提供的上下文。
relevance	是否直接回答 query。
completeness	是否覆盖 expected_answer_points。
citation_support	是否用 chunk_id 支撑关键陈述。
hallucination_risk	是否引入上下文外信息，风险越高越差。
overall_answer_score	综合答案质量分，进入总分公式。

重要原则：没有 API key 时不阻塞 MVP。内容团队仍然可以依赖 retrieval、citation、entity、structure 四类指标做上线前改稿。

8. 总 GEO Score：如何把批判结果合成一个分数

总分满分 100。它不是绝对真理，而是为了让旧稿、新稿、不同版本之间可以稳定比较。

场景	Retrieval	Citation	Answer	Entity	Structure
answer_score 可用	35%	25%	20%	10%	10%
answer_score 不可用	45%	30%	0%	12.5%	12.5%

提升判断: $\text{absolute_delta} = \text{new_total} - \text{old_total}$; $\text{relative_delta_percent} = \text{absolute_delta} / \text{old_total} \times 100\%$ 。winner 按 delta 大于、小于或等于 0 判定。

9. 如何读报告并指导改稿

报告区域	内容团队应该看什么	典型行动
Executive Summary	总分、赢家、提升幅度。	判断新稿是否值得进入发布候选。
Retrieval Performance	哪些 query 的 new_rank 没有改善，哪些 query 的 MRR 低。	把对应用户问题改写成 H2/FAQ/direct answer。
Query-Level Diagnosis	old/new Top chunks 的文本差异。	补充缺失 claim，重写命中但不可引用的 chunk。
Citation Readiness	强/弱 chunk、vague phrase、reasons。	把营销句改成定义、对比、步骤、可测量表述。
Entity Coverage	missing_entities 与 inconsistent_terms。	补齐平台、品牌、主题实体，并统一命名。
Structure Analysis	长段落、缺 FAQ、缺 summary、缺 direct answer。	拆 section、加 FAQ、加 Definition 或 Key takeaways。
Raw Outputs	CSV/JSON 明细。	交给策略或产品做二次分析、仪表盘或版本追踪。

推荐改稿顺序

- 先修 query 级失败：new_rank 低于 old_rank、Hit@3=0、MRR 显著下降的 query 优先。
- 再修 citation weak chunks：尤其是 Top K 中被检索到但 citation_score 低的 chunk。
- 补实体：缺平台实体、品牌实体或核心 topic entity 会影响 AI 对主题归因。
- 最后修结构：FAQ、summary、H2/H3、direct answer blocks 能提高下一轮 chunking 与 retrieval 稳定性。

10. MVP 的边界与后续升级

这个系统故意不依赖真实 crawler indexing，也不修改生产网站。它批判的是“如果这篇内容被拿去做检索语料，它是否更可能被取回、引用并支撑答案”。

当前 MVP 边界	后续可升级方向
相关性主要依赖 target_article 与关键词重合。	加入人工 relevance label、query intent 权重、负样本和 competitor 页面。
BM25 tokenizer 简单 lowercase split。	加入分词、同义词、实体词典、query expansion。
Embedding 默认 local/fallback，可能与真实 LLM retrieval 不完全一致。	接入 OpenAI embeddings、向量库、真实 RAG 配置回放。
Citation score 是启发式。	加入 LLM citation judge 与 factual claim verifier。
Answer eval 依赖 OPENAI_API_KEY。	接入多模型 judge、RAGAS、人工审核闭环。

附录：核心文件与输出

模块/文件	作用
geo_backtester/chunking/chunker.py	按 token/overlap 切分文章并保留 heading context。
geo_backtester/retrieval/bm25_retriever.py	BM25 词面检索。
geo_backtester/retrieval/embedding_retriever.py	语义检索；OpenAI、sentence-transformers、TF-IDF fallback。
geo_backtester/retrieval/hybrid_retriever.py	BM25 + embedding 归一化融合。
geo_backtester/evaluation/retrieval_metrics.py	Hit@K、MRR、average_rank、rank_delta、winner。
geo_backtester/evaluation/citation_eval.py	引用价值启发式评分。
geo_backtester/evaluation/entity_eval.py	实体覆盖与命名一致性检查。
geo_backtester/evaluation/structure_eval.py	标题、段落、FAQ、summary、direct answer 结构评分。
geo_backtester/evaluation/geo_score.py	总 GEO score 权重公式。
outputs/runs/{run_id}/	retrieval_results.csv、citation_results.csv、answer_results.csv、score_summary.json、report.html。